



Московский физико-технический
институт

Кафедра прикладной математики

Прайсинг деривативов с помощью нейронных сетей

Нейросетевой суррогат модели Хестона: калибровка, оценка
неопределённости и LSTM-динамика параметров

Студент: Бирюков Никита Алексеевич

Науч. руководитель: Андреев Михаил Владимирович

Дата: 26 мая 2026 г.

Постановка задачи

Проблема: классическая калибровка медленна

- 1 Вычислить характеристическую функцию $\phi(u; \theta)$
- 2 Оценить 88 опционов через FFT Карра–Мадана
- 3 Подать MSE в оптимизатор Левенберга–Марквардта
- 4 Повторить $\sim 10\,000$ раз до сходимости

⇒ **10–120 секунд** на одну калибровку

⇒ Нет аналитического якобиана

Практические требования

- ✓ Реал-тайм трейдинг: жёсткий дедлайн < 150 мс
- ✓ Точные производные второго порядка (Греки)
- ✓ Гарантия физических ограничений (усл. Феллера)

Цель дипломной работы

Создать универсальный ML-фреймворк для калибровки различных моделей ценообразования и оценить его применимость в продакшене.

Суррогат Хестона — первый шаг реализации (Proof of Concept).

Задачи реализации (на примере Хестона):

- Ф1 Обучить MLP-суррогат $\mathcal{N}_w : \mathbb{R}^5 \rightarrow \mathbb{R}^{88}$ в пространстве суммарной дисперсии W
- Ф2 Реализовать байесовскую оценку неопределённости (MC Dropout)
- Ф3 Обучить LSTM для прогнозирования динамики параметров на следующий день

Нейросетевой суррогат



Обзор существующих ML-подходов к прайсингу деривативов

Метод	Задача	Архитектура	Сложность / Ресурсы
Deep BSDE (Han et al., 2018)	Прайсинг при $d \sim 100$, нелинейные PDE	MLP на каждом шаге времени	Средняя (GPU Tesla T4)
DGM (Sirignano et al., 2018)	Американские опционы, свободная граница	ResNet/LSTM-слой	Высокая (V100/A100)
Deep Hedging (Buehler et al., 2019)	Хеджирование с транзакционными издержками	LSTM (path-dependent)	Средняя/Высокая
Deep Calibration (Horvath et al., 2019)	Мгновенная калибровка поверхности IV	MLP-суррогат	Низкая (любой GPU)



Почему Deep Calibration?

- Обучение **один раз** — инференс мгновенный
- Градиент через autograd $\Rightarrow$ точный якобиан
- Малые требования к железу (RTX 3060)
- Прямое расширение на LSTM (Фаза 3)




Почему не альтернативы?


- Deep BSDE: нет якобиана, нет поверхности
- DGM: чрезмерные вычислительные ресурсы
- Deep Hedging: другая задача (трения)

Архитектура системы: трёхфазный pipeline


Фаза 1 — MLP-суррогат



Фаза 2 — MC Dropout



Фаза 3 — LSTM-динамика



Пунктирная стрелка: поверхности W из Фазы 1 служат входом для обучения Фазы 3



Фаза 1: суррогатная модель MLP

Архитектура нейросети:



Параметр	Значение
Архитектура	4×30 , ELU (C^2)
Параметров	5 698
Оптимизатор	Adam + ReduceLROnPlateau
Эпох	200, RTX 3060, ≈ 2 мин

Пространство суммарной дисперсии W

Сеть предсказывает не IV напрямую, а:

$$W(K, T) = \sigma_{IV}^2(K, T) \cdot T$$

- ✓ Линеаризует уравнение Дюпира
- ✓ Условие без арбитража: $\partial W / \partial T \geq 0$ (критерий Карра–Мадана)
- ✓ Стабилизирует градиенты при обучении

Зачем ELU, а не ReLU?


ReLU: $f''(x) \equiv 0 \Rightarrow$ гессиан нулевой, греки бессмысленны

ELU: $f''(x) \neq 0 \Rightarrow$ корректный гессиан

$$\|H_{ELU}\|_F = 1.039 \gg \|H_{ReLU}\|_F = 0$$

Результаты: калибровка поверхности волатильности

3D-поверхность IV: цель vs калибровка



Синяя поверхность — целевая рыночная IV; Оранжевая — откалиброванная нейросетью

Параметры (тестовый пример):

Пар-р	Истинный	NN	$ \Delta $
v_0	0.00198	0.00236	0.00038
ρ	-0.877	-0.950	0.073
σ	0.0776	0.0663	0.011
θ	0.1847	0.1844	0.000
κ	5.582	5.538	0.044

Итоговые метрики


Val RMSE (W -пространство)	0.0876
Время калибровки	47–135 мс
Нарушений арбитража	0 / 77
Условие Феллера	✓ всегда

Сетка поверхности

8 сроков экспирации $\times$ 11 страйков = 88 точек

Производительность: ускорение в ≈ 160 раз

Время одной калибровки (CPU):



$\approx 160\times$ быстрее

Почему так быстро?

- 1 Один **forward-pass** MLP вместо 10 000 итераций FFT
- 2 Точный якобиан через autograd $\Rightarrow$ L-BFGS-B за единицы итераций
- 3 Нет Фурье-интеграла на каждом шаге оптимизатора

Метод	CPU	GPU
FFT + LM	10–120 с	~ 5 с
NN-суррогат	47–135 мс	<10 мс



Применимость

- HFT: дедлайн <100 мс ✓
- Портфельная переоценка в реал-тайм ✓
- Батч-калибровка тысяч инструментов ✓

Фаза 2: байесовская оценка неопределённости (MC Dropout)

Зачем оценивать неопределённость?

Точечная калибровка не говорит, насколько уверена модель в своём предсказании.

Алгоритм MC Dropout (Gal & Ghahramani, 2016)

- 1 Оставить Dropout ($p=0.1$) **активным** на инференсе (`model.train()`)
- 2 Выполнить $N = 100$ стохастических forward-pass
- 3 Вычислить среднее μ и std σ по семплам

$$\hat{\sigma} \pm 2\sigma_{MC}$$


⇒ **доверительный интервал** поверхности IV

Математическая интерпретация

Байесовское приближение над весами:

$$p(\sigma^* | \theta, \mathcal{D}) \approx \frac{1}{N} \sum_{i=1}^N \mathcal{N}_{w_i}(\theta)$$

Схема 100 forward-pass:



Результаты ($N = 100$)


Макс. σ_{MC} (АТМ, $T = 1$)	$< 5 \times 10^{-4}$
Ширина полос $\pm 2\sigma$	$< 0.1\%$ IV
Накладные расходы	$\approx 100\times$

Узкие полосы подтверждают отсутствие переобучения.

Фаза 3: LSTM-прогноз динамики параметров Хестона

Задача: предсказать $\hat{\theta}_{t+1}$ по истории поверхностей W за 10 дней.

Архитектура:



Параметр	Значение
LSTM слоёв	2, hidden = 64
Инициализация	Xavier (вход), Ортогональная (рекурр.)
Forget-gate bias	= 1 (стандартный трюк)
Нормализация	LayerNorm после LSTM
Обучаемых пар-ов	73 157
Оптимизатор	AdamW + CosineAnnealingLR
Ранняя остановка	EarlyStopping (patience=20)

Генерация обучающих данных

- 1 **600 траекторий** параметров по процессам Орнштейна–Уленбека (калибр. к SPX)
- 2 Каждый день: $\theta_t \xrightarrow{\text{MLP}} W_t$ (88 точек)
- 3 **102 000 окон:** $(W_{t-9}, \dots, W_t) \rightarrow \theta_{t+1}$
- 4 Разбивка 80/10/10 по границам траекторий (утечки данных нет)

Z-нормализация меток

Метки θ нормализуются по статистике обучающей выборки (Z-score).


На инференсе: обратное преобразование + жёсткая привязка к физическим границам (условие Феллера гарантировано).

Результаты Фазы 3: точность прогноза LSTM

RMSE по параметрам (оригинальный масштаб):

Пар-р	Физ. смысл	RMSE
v_0	Нач. дисперсия	0.0052
ρ	Корреляция	0.0133
σ	Вол-ть вол-ти	0.0257
θ	Долгоср. дисперсия	0.0035
κ	Скор. возврата	0.1270
Норм. RMSE (тестовая выб.)		0.336
Норм. MSE (тестовая выб.)		0.113

RMSE по каждому параметру:



Тестовая выборка: 10 200 последовательностей (10% от 102 000 окон)

Вывод

κ сложнее всего: быстро меняется.
 θ и v_0 прогнозируются точнее — медленная средняя динамика OU-процесса.



Демонстрация: интерактивный Streamlit-дашборд

Веб-приложение (Streamlit):


Вкладка 1 — Демо калибровки

- Ползунки $\kappa, \theta, \sigma, \rho, v_0$ + живая проверка условия Феллера
- «Сгенерировать поверхность» — MLP forward-pass
- «Откалибровать» — L-BFGS-B, 3D-сравнение IV
- «Неопределённость» — 100 MC Dropout passes, $\pm 2\sigma$ полосы
- «Прогноз» — OU-симуляция $\rightarrow$ LSTM $\rightarrow$ траектория 5 параметров

Вкладка 2 — Архитектура & Методы

- Интерактивный граф вычислений (Cytoscape.js)
- Клик по узлу $\rightarrow$ формулы на KaTeX + фрагмент

Живое демо:



hestondl.streamlit.app

```
src/app.py — Streamlit UI
src/model.py — HestonSurrogateMLP
src/seq_model.py — HestonDynamicsLSTM

tests/ — pytest (29 тестов)
```



Выводы и направления дальнейшего развития

Достигнутые результаты:

- ✓ **Фаза 1 — MLP-суррогат:**
Val RMSE **0.0876**; калибровка за **47–135 мс**;
ускорение $\approx 160\times$; 0 нарушений арбитража
- ✓ **Фаза 2 — MC Dropout:**
Доверительные полосы $\pm 2\sigma < 0.1\%$ IV;
байесовская неопределённость без доп.
архитектуры
- ✓ **Фаза 3 — LSTM-динамика:**
102 000 обучающих окон; норм. RMSE **0.336**;
Феллер гарантирован на каждом инференсе
- ✓ **Инфраструктура:**
29 pytest-тестов (100% pass); интерактивный
Streamlit-дашборд; живое демо
`hestondl.streamlit.app`

→ Направления развития

- ➊ **Rough Volatility:** замена Heston на rBergomi / rHeston (дробное броуновское движение)
- ➋ **Реальные рыночные данные:** калибровка на исторических SPX-опционах вместо синтетики
- ➌ **Deep Hedging:** использование суррогата как среды для обучения стратегий хеджирования с транзакционными издержками
- ➍ **REST API / облако:** обёртка FastAPI + контейнеризация Docker для продакшн-развёртывания

Спасибо за внимание! 